

Enfermedad de Huntington

Pipeline bioinformático del gen *HTT*

Introducción a la Bioinformática (K5061) — UTN FRBA · 2026

Profesor: Patricio Yankilevich

Integrantes: Tomás Guillermo León · Gustavo Di Peppe · Alejo Gurfein · Hernán Hrib

Agenda

1. **Introducción** — la enfermedad y el gen
2. **Métodos** — stack y reproducibilidad
3. **Resultados** por ejercicio
 - Ej1 marcos de lectura · Ej2 BLAST · Ej3 MSA
 - Ej4 parser BLAST · Ej5 EMBOSS/PROSITE
 - Ej6 bases de datos biológicas
4. **Conclusiones**

10 min · ~15 slides

La enfermedad de Huntington

- Enfermedad **neurodegenerativa hereditaria**, autosómica **dominante** (OMIM #143100).
- Deterioro progresivo: **movimiento, cognición y conducta**. Sin cura.
- **No hay portadores sanos**: quien hereda el alelo mutado desarrolla la enfermedad.

Por qué la elegimos: causa molecular única y muy clara → caso ideal para recorrer todo el pipeline, de la secuencia a la variante patogénica.

Causa molecular: expansión CAG

- Expansión inestable del triplete **CAG** en el exón 1 de *HTT*.
- Se traduce en un tracto de **poliglutaminas (polyQ)** tóxico para las neuronas.

Nº repeticiones CAG	Fenotipo
≤ 35	Normal
36–39	Penetrancia incompleta
≥ 40	Penetrancia completa — HD
≥ 60	Forma juvenil

A más repeticiones → inicio más temprano y curso más grave.

El gen *HTT*

- Cromosoma **4p16.3**, ~180 kb, **67 exones**.
- Codifica la **huntingtina** (~3144 aa): proteína de **andamiaje** del transporte axonal, transporte de BDNF, autofagia, desarrollo neuronal.
- Secuencia de referencia del TP: **NM_002111.8** (NCBI Nucleotide).

Métodos — ambiente de trabajo

- **Lenguaje:** Python 3.11 + **BioPython**
- **BLAST+** y **EMBOSS** (getorf, patmatmotifs)
- **Docker** sobre Windows → reproducibilidad
- **Git/GitHub** → control de versiones

```
docker compose run tp python src/ex1_reading_frames.py
docker compose run tp python src/ex2_blast.py
docker compose run tp python src/ex3_msa.py
docker compose run tp python src/ex4_blast_parser.py "Mus musculus"
docker compose run tp python src/ex5_emboss.py
```

Ej1 — Marcos de lectura

Leer GenBank → 6 marcos (+1/+2/+3 y -1/-2/-3) → traducir → FASTA.

Frame	aa antes del 1er stop	Observación
+1	131	stop prematuro
+2	3192	frame correcto
+3	27	stop prematuro
-1 / -2 / -3	23 / 13 / 5	stop prematuro

El frame +2 (3192 aa) coincide con el tamaño conocido (~3144 aa). La diferencia con el resto es enorme — pero el frame se **confirma** en el Ej2 con BLAST.

Ej2 — BLAST (conservación evolutiva)

`blastp` remoto contra SwissProt. Solo el frame +2 dio hits significativos.

#	Proteína	Organismo	Identity	E-value
1	Huntingtin	<i>Homo sapiens</i>	99.9%	0.0
2	Huntingtin	<i>Mus musculus</i>	91.2%	0.0
3	Huntingtin	<i>Rattus norvegicus</i>	90.8%	0.0
4	Huntingtin	<i>Takifugu rubripes</i>	69.7%	0.0
5	HD homolog	<i>Dictyostelium discoideum</i>	28.8%	8e-19

Homólogo hasta en una **ameba** → gen **muy antiguo** (eucariotas en general).
También se corrió BLAST **local** contra SwissProt (482.697 secuencias).

Ej3 — Alineamiento múltiple (MSA)

- MSA de la huntingtina en 5 especies (humano, ratón, rata, pez globo, *Dictyostelium*).
- Las posiciones **conservadas en todas** las especies son funcionalmente críticas.
- Salida: `output/msa.aln`.

Ej4 — Parser de salida BLAST

- Script que **parsea** `blast.out` y filtra hits cuya descripción contiene un **Pattern** (ej. `"Mus musculus"`, case-insensitive).
- Punto extra: extrae el **ACCESSION** de cada hit y baja la secuencia completa en FASTA con `Bio.Entrez` (equivalente a `Bio::DB::GenBank`).

```
docker compose run tp python src/ex4_blast_parser.py "Mus musculus"  
# → output/ex4_hits.fasta
```

Ej5 — EMBOSS: ORFs + dominios PROSITE

- `getorf` → ORFs del mRNA; se elige el más largo = **huntingtina (3144 aa)**.
- `prosextract` + `patmatmotifs` → análisis de dominios contra **PROSITE**.

Motivos encontrados (HitCount: 4):

Motivo	Posición
AMIDATION	2545–2548
AMIDATION	1532–1535
LEUCINE_ZIPPER	1446–1467
TYR_PHOSPHO_SITE_2	2716–2723

Ej6 — Bases de datos biológicas (1/2)

Pregunta	Resultado (verificado jun 2026)
Homólogos	HomoloGene (legacy, ~9–11 spp) vs Ensembl: 412 ortólogos
Transcriptos	RefSeq 2 reviewed vs Ensembl 24 (10 coding)
Interacciones	HAP1, HIP1, HIP14, DCTN1... → patrón: transporte sobre microtúbulos
GO	citoplasma/vesículas · transporte axonal · <i>protein binding</i>
Pathways	KEGG hsa05016 "Huntington disease" · Reactome

Diferencia metodológica clave: RefSeq curado/conservador vs Ensembl automático/exhaustivo.

Ej6 — La variante patogénica (2/2)

- No es un SNP clásico: es una **expansión de microsatélite** (CAG).
- **ClinVar Variation ID 409** — *Pathogenic, review practice guideline*.

Frecuencia / etnia:

- Mayor en **ascendencia europea** (~5–15/100.000), haplogrupo A — efecto fundador.
- Mucho menor en Asia oriental y África subsahariana.
- Caso emblemático: **Lago de Maracaibo** (Venezuela) → clonado del gen en 1993.

Conclusiones

- *HTT* es un gen **antiguo y muy conservado** (de amebas a humanos).
- El pipeline completo —de la secuencia a la variante— confirmó la **causa molecular**: expansión **CAG / polyQ**.
- Las herramientas coinciden y se complementan: BLAST, MSA, EMBOSS/PROSITE y bases de datos cuentan la misma historia desde ángulos distintos.
- Diferencias entre bases (RefSeq vs Ensembl, HomoloGene legacy) → importa **saber qué base usar** según el objetivo.

¡Gracias!

¿Preguntas?

Repo: github.com/hhrib/tp-bioinformatica-2026