



UTN.BA

Bioinformática - K5061

Integrantes – Año 2026

Nombre	E-Mail
Tomás Guillermo León	tleon@frba.utn.edu.ar
Gustavo Di Peppe	gdipeppe@frba.utn.edu.ar
Alejo Gurfein	agurfein@frba.utn.edu.ar
Hernán Hrib	hhrib@frba.utn.edu.ar

Profesor a cargo del curso: Patricio Yankilevich

Trabajo Práctico Parte 1 — Informe de Avance

Introducción a la Bioinformática — UTN FRBA

Fecha de entrega: 1 de junio de 2026

1. Introducción

Enfermedad elegida: Enfermedad de Huntington

La Enfermedad de Huntington (EH) es una enfermedad hereditaria catalogada en OMIM bajo el número #143100. La elegimos porque tiene una causa genética muy clara y bien documentada, lo que la hace ideal para trabajar con herramientas bioinformáticas. Se caracteriza por un deterioro progresivo que afecta el movimiento, la cognición y el comportamiento, y no tiene cura.

Lo que más nos llamó la atención al investigarla es que no existen portadores sanos: cualquier persona que herede el alelo mutado va a desarrollar la enfermedad en algún momento de su vida. Eso la hace diferente a la mayoría de las enfermedades hereditarias.

****Causa molecular:**** la elegimos por ser una enfermedad conocida y hereditaria

Gen elegido: HTT (Huntingtin)

El gen HTT está en el cromosoma 4 y codifica para la proteína huntingtina. Según la base de datos SwissProt, la proteína tiene alrededor de 3144 aminoácidos. La secuencia de referencia que usamos en este trabajo es el transcripto **NM_002111.8** obtenido de NCBI Nucleotide.

2. Ambiente de trabajo

El trabajo fue desarrollado utilizando:

- **Lenguaje:** Python 3.11 con la librería BioPython
- **Ambiente:** contenedor Docker sobre Windows, garantizando reproducibilidad
- **Control de versiones:** repositorio Git en GitHub
- **BLAST:** ejecutado de forma remota contra la base de datos SwissProt del NCBI

Para reproducir el ambiente y ejecutar los scripts:

```
docker compose run tp bash
python src/ex1_reading_frames.py
python src/ex2_blast.py
python src/ex3_msa.py
```

3. Ejercicio 1 — Procesamiento de Secuencias

Descripción

Se desarrolló el script `src/ex1_reading_frames.py` que realiza las siguientes operaciones:

1. Lee el archivo `data/NM_002111.gb` en formato GenBank usando `Bio.SeqIO`
2. Extrae la secuencia de nucleótidos del mRNA maduro de HTT (13.498 bp)

3. Calcula los **6 marcos de lectura posibles**: +1, +2, +3 sobre la cadena directa y -1, -2, -3 sobre el complemento reverso
4. Traduce cada marco a su secuencia de aminoácidos usando la tabla de código genético estándar
5. Escribe los 6 resultados en el archivo `output/orfs.fasta` en formato FASTA

Nota de implementación: Al investigar las herramientas disponibles se encontró que BioPerl ofrece `Bio::SeqUtils->translate_6frames()`, función que calcula los 6 marcos de lectura incluyendo los frames negativos (-1, -2, -3) sobre el complemento reverso de la secuencia, y devuelve 6 objetos de secuencia directamente utilizables. BioPython cuenta con `Bio.SeqUtils.six_frame_translations()` que realiza el mismo cálculo pero devuelve un string formateado para visualización, no objetos procesables. Por este motivo se implementó la función `get_six_frames()` utilizando las primitivas `seq.reverse_complement()` y `seq.translate()`, reproduciendo el comportamiento de la función de BioPerl.

Resultados

Frame	Aminoácidos antes del primer stop	Observación
+1	131	Stop prematuro
+2	3192	Frame correcto
+3	27	Stop prematuro
-1	23	Stop prematuro
-2	13	Stop prematuro
-3	5	Stop prematuro

El frame correcto es el +2, con 3192 aminoácidos antes del primer codón de stop, coherente con el tamaño conocido de la huntingtina humana (~3144 aa). Los otros 5 marcos producen proteínas truncadas de menos de 132 aminoácidos, lo que indica que no corresponden al marco de lectura real.

Conclusión del ejercicio

Lo que más me llamó la atención al ver los resultados fue la diferencia de longitudes: el frame +2 produce 3192 aminoácidos antes del primer stop, y el segundo mejor llega solo a 131. No hacía falta saber de antemano cuál era el correcto — la diferencia es tan grande que se ve sola. Igual, en este ejercicio no determinamos el frame correcto: eso lo confirmamos recién en el ejercicio 2 con BLAST, que es el criterio más sólido.

4. Ejercicio 2a — BLAST

Descripción

Se desarrolló el script `src/ex2_blast.py` que:

1. Lee los 6 frames del archivo `output/orfs.fasta` (output del Ejercicio 1)
2. Ejecuta una búsqueda **blastp remota** contra SwissProt del NCBI para cada frame usando `Bio.Blast.NCBIWWW`
3. Guarda todos los resultados en `output/blast.xml` (para el Ejercicio 3) y en `output/blast.out` (reporte legible en texto plano)
4. Muestra un resumen por frame indicando cuántos hits significativos obtuvo cada uno

Resultados

El BLAST remoto se corrió sobre los 6 frames para identificar el correcto sin conocimiento previo. Solo el frame +2 produjo hits significativos:

Frame	aa antes del stop	Hits significativos	Mejor E-value
+1	131	0	—
-1	23	0 (E-value: 1.40)	—
+2	3192	5	0.0
-2	13	0	—
+3	27	0	—
-3	5	0	—

Los 5 hits del frame +2:

#	Proteína	Organismo	Identity	E-value	Score
1	Huntingtin (HD_HUMAN)	<i>Homo sapiens</i>	99.9%	0.0	16720
2	Huntingtin (HD_MOUSE)	<i>Mus musculus</i>	91.2%	0.0	14691
3	Huntingtin (HD_RAT)	<i>Rattus norvegicus</i>	90.8%	0.0	14620
4	Huntingtin (HD_TAKRU)	<i>Takifugu rubripes</i>	69.7%	0.0	11538
5	HD protein homolog	<i>Dictyostelium discoideum</i>	28.8%	8.22e-19	244

BLAST local

Además del BLAST remoto, se ejecutó un BLAST local contra una copia descargada de SwissProt (482.697 secuencias). Se descargó la base de datos en formato FASTA desde el FTP del NCBI y se la formateó con `makeblastdb` . El query utilizado fue el mismo que en el BLAST remoto: la secuencia proteica del frame +2 extraída de `output/orfs.fasta` (3192 aa). El comando ejecutado fue:

```
blastp.exe -db C:\Users\herna\facu\bioinformatica-2026\tp-bioinformatica-2026\data\swissprot\swissprot -query C:\Users\herna\facu\bioinformatica-2026\tp-bioinformatica-2026\output\orfs.fasta -out C:\Users\herna\facu\bioinformatica-2026\tp-bioinformatica-2026\output\local-ncbi-blast-repos.txt
```

El resumen de hits significativos producido por BLAST para el frame +2:

```
Query= NM_002111.8_frame_+2

Sequences producing significant alignments:                                (Bits)  Value

P42858.2 RecName: Full=Huntingtin [Homo sapiens]                        6397    0.0
P42859.2 RecName: Full=Huntingtin [Mus musculus]                        5616    0.0
P51111.1 RecName: Full=Huntingtin [Rattus norvegicus]                    5589    0.0
P51112.1 RecName: Full=Huntingtin [Takifugu rubripes]                    4424    0.0
Q76P24.1 RecName: Full=HD protein homolog [Dictyostelium discoideum]    97.4    3e-18
```

Los resultados son consistentes con el BLAST remoto, confirmando ambos análisis:

#	Accesión	Proteína	Organismo	Identidad	E-value	Bit score
1	P42858.2	Huntingtin (HD_HUMAN)	<i>Homo sapiens</i>	99% (3142/3144)	0.0	6397
2	P42859.2	Huntingtin (HD_MOUSE)	<i>Mus musculus</i>	91% (2792/3063)	0.0	5616
3	P51111.1	Huntingtin (HD_RAT)	<i>Rattus norvegicus</i>	91% (2781/3063)	0.0	5589
4	P51112.1	Huntingtin (HD_TAKRU)	<i>Takifugu rubripes</i>	70% (2245/3223)	0.0	4424
5	Q76P24.1	HD protein homolog	<i>Dictyostelium discoideum</i>	29%	3e-18	97.4

El hit 1 muestra 99% (3142/3144) y no 100% porque la traducción del frame +2 incluye 2 aminoácidos extra en el N-terminal respecto a la secuencia curada de SwissProt (P42858.2, 3142 aa), lo que genera 2 gaps en el alineamiento. Esto es esperable: el frame +2 traduce desde la posición 2 del mRNA crudo, mientras que la secuencia SwissProt representa la proteína procesada y anotada manualmente.

5. Ejercicio 2b — Interpretación del resultado BLAST

Significado de los valores estadísticos

E-value (Expect value): es la cantidad de hits que esperarías encontrar por azar en una base de datos del tamaño de SwissProt con una puntuación igual o mejor. Un E-value de 0.0 significa que esa probabilidad es tan pequeña que Python la redondea a cero — el hit es real. El hit 5 (*Dictyostelium*) con E-value de 8.22e-19 también es significativo: hay 1 en 10¹⁹ chances de que esa similitud sea producto del azar. En general, se considera significativo cualquier E-value menor a 0.001.

Identity %: porcentaje de aminoácidos idénticos en el alineamiento. Los hits 2, 3 y 4 (ratón, rata y pez globo) presentan alta identidad con la huntingtina humana, lo que indica que el gen HTT está fuertemente conservado en vertebrados.

Score: mide la calidad del alineamiento sumando puntos por cada posición — aminoácidos idénticos suman más, similares suman menos, gaps restan. Existen dos variantes: el **raw score** depende de los parámetros de configuración usados y no es comparable entre distintas corridas; el **bit score** es una versión normalizada del raw score que sí es comparable entre cualquier corrida de BLAST. Por eso el BLAST remoto y el local reportan scores distintos para los mismos hits: el remoto usa raw score y el local bit score.

Interpretación biológica

Los primeros 4 hits corresponden a la huntingtina de otros vertebrados, con identidades superiores al 69%. Esto demuestra que HTT es un gen altamente conservado en vertebrados, lo que implica que cumple funciones celulares fundamentales más allá de la patología asociada en humanos.

El hit más sorprendente es el número 5: *Dictyostelium discoideum*, que es una ameba unicelular. No esperábamos encontrar un homólogo de huntingtina en un organismo tan distinto a los vertebrados. Con 28.8% de identidad

todavía tiene regiones similares, lo que sugiere que este gen existe desde hace muchísimo tiempo y probablemente cumple alguna función básica en la célula.

Conclusión del ejercicio

Correr BLAST sobre los 6 frames sin saber cuál era el correcto resultó ser la forma más directa de identificarlo: solo el frame +2 dio hits reales, todos los demás no encontraron nada. Eso ya responde la pregunta del ejercicio 1.

Lo que no esperaba era la ameba. Que exista un homólogo en *Dictyostelium discoideum* me hizo entender que la huntingtina no es solo una proteína asociada a una enfermedad humana — debe tener alguna función más básica que se conservó a lo largo de la evolución. También fue útil comparar el BLAST remoto con el local: los dos dieron los mismos 5 hits en el mismo orden, lo que me da más confianza en los resultados.

6. Ejercicio 3 — Multiple Sequence Alignment (MSA)

Descripción

Se desarrolló el script `src/ex3_msa.py` que descarga automáticamente las secuencias proteicas de los 5 hits encontrados en el BLAST desde NCBI usando `Bio.Entrez`. Las secuencias fueron guardadas en `output/msa_input.fasta` y el alineamiento múltiple fue realizado con **Clustal Omega** (versión online, EMBL-EBI). El resultado se guardó en `output/msa.aln`.

Las especies incluidas en el MSA son:

Código	Especie	Identidad con HTT humana
HD_HUMAN	<i>Homo sapiens</i>	referencia
HD_MOUSE	<i>Mus musculus</i>	91.2%
HD_RAT	<i>Rattus norvegicus</i>	90.8%
HD_TAKRU	<i>Takifugu rubripes</i> (pez globo)	69.7%
HD_DICDI	<i>Dictyostelium discoideum</i> (ameba)	28.8%

Interpretación del alineamiento

Al abrir el archivo de alineamiento lo primero que se ve son los símbolos `*`: indican posiciones donde todas las especies tienen el mismo aminoácido. Hay muchos en la parte central y final de la secuencia, lo que significa que esas regiones se mantuvieron iguales a lo largo de la evolución.

Lo más llamativo está al principio de la secuencia:

HD_HUMAN	MATLEKLMKAFESLKSFQQQQQQQQQQQQQQQQQQPPPPP...
HD_MOUSE	MATLEKLMKAFESLKSFQQQQQQQQPP...
HD_RAT	-----MKAFESLKSFQQQQQQQP...
HD_TAKRU	MATMEKLMKAFESLKSFQQQQG...
HD_DICDI	-----MD

La secuencia humana tiene una cadena mucho más larga de Q repetidas que el resto de las especies. Esa región es exactamente donde ocurre la expansión de repeticiones CAG que causa la enfermedad — cada Q en la proteína corresponde a un CAG en el ADN. Verlo directamente en el alineamiento fue bastante impactante porque conecta todo el análisis con la causa molecular de la enfermedad.

En el resto de la secuencia, ratón y rata son muy similares a la humana. El pez globo tiene más diferencias pero todavía comparte bastantes posiciones. La ameba es la que más gaps tiene y menos * muestra, aunque aparecen algunos bloques conservados en distintos lugares de la secuencia.

Conclusión del ejercicio

Al ver el alineamiento lo primero que se nota es que ratón y rata son casi iguales a la secuencia humana, lo cual tiene sentido porque son mamíferos. El pez globo ya diverge más pero todavía comparte regiones. La ameba tiene la mayor cantidad de gaps y es la más distinta, pero que aparezca en el alineamiento con bloques conservados es lo que más me sorprendió de todo el trabajo. También fue interesante poder ver directamente en el alineamiento la región de glutaminas (Q) que causa la enfermedad — los humanos tienen una cadena mucho más larga que el resto.



Alineamiento múltiple de huntingtina

Resultado completo del MSA disponible en: <https://www.ebi.ac.uk/jdispatcher/msa/clustalo/summary?jobId=clustalo-120260526-034619-0482-90639946-p1m>

7. Conclusión parte 1

Este trabajo me resultó más interesante de lo que esperaba. Empezamos con un archivo de texto en formato GenBank y terminamos viendo en el alineamiento la región exacta que causa la enfermedad.

Lo que más me quedó fue la progresión: el ejercicio 1 traduce los 6 frames sin saber cuál es el correcto, el ejercicio 2 lo identifica a través de BLAST, y el ejercicio 3 permite visualizar las diferencias entre especies. Cada paso tiene sentido en función del siguiente.

La sorpresa fue la ameba. Que un organismo tan distinto a nosotros tenga una versión del mismo gen sugiere que la proteína cumple alguna función muy básica — algo que no habría notado sin hacer el análisis. Y ver en el alineamiento que la cadena de Q repetidas es más larga en humanos que en cualquier otra especie cierra el círculo con la causa molecular de la enfermedad.

8. Ejercicio 4 — Parser de la salida de BLAST

Descripción

Se desarrolló el script `src/ex4_blast_parser.py`, que toma como entrada el reporte `output/blast.out` generado en el Ejercicio 2 y un **Pattern** pasado como parámetro por línea de comandos (por defecto `"Mus musculus"`, como en el ejemplo de la consigna). El script recorre el reporte e identifica los hits cuya descripción contiene ese Pattern, de forma **case-insensitive** (para que `"mus musculus"` y `"Mus musculus"` coincidan).

Para distinguir las filas de hit de las líneas decorativas del reporte se usa una expresión regular que detecta el **ACCESSION** al inicio de cada fila (formato tipo `P42859.2`). Además, mientras recorre el archivo, el script va guardando el frame actual (`Frame +2`, etc.) para poder indicar en qué marco de lectura apareció cada hit.

Punto extra: para cada hit que coincide con el Pattern, el script extrae su **ACCESSION** y descarga la secuencia completa de la proteína en formato FASTA desde NCBI usando `Bio.Entrez` (el equivalente en BioPython al módulo `Bio::DB::GenBank` de BioPerl que menciona la consigna), y la escribe a `output/ex4_hits.fasta`.

```
docker compose run tp python src/ex4_blast_parser.py "Mus musculus"
# input:  output/blast.out + Pattern
# output: output/ex4_hits.fasta
```

Resultados

Ejecutando con el Pattern `"Mus musculus"` sobre el `blast.out` del Ejercicio 2, el script encontró **1 hit** que coincide:

Frame	Accession	Descripción
+2	P42859.2	Huntingtin — <i>Mus musculus</i> (ratón)

A continuación descargó la secuencia completa de ese hit desde NCBI y la guardó en `output/ex4_hits.fasta`:

```
>sp|P42859.2|HD_MOUSE RecName: Full=Huntingtin; AltName: Full=Huntington
disease protein homolog; Short=HD protein homolog; ...
```

Si se ejecuta con otro Pattern (por ejemplo `"Rattus"` o `"Takifugu"`) el script devuelve los hits correspondientes a esa otra especie, lo que confirma que el filtro funciona de forma genérica.

Conclusión del ejercicio

El ejercicio muestra cómo procesar de forma programática la salida de una herramienta como BLAST en lugar de leerla a mano. Lo más interesante fue el punto extra: con solo el **ACCESSION** del hit se puede recuperar automáticamente la secuencia original completa desde NCBI, encadenando el resultado del BLAST con una nueva consulta a la base de datos. Esto deja todo listo para análisis posteriores (por ejemplo, un alineamiento) sin pasos manuales.

9. Ejercicio 5 — EMBOSS (ORFs y dominios PROSITE)

Descripción

Se desarrolló el script `src/ex5_emboss.py`, que arma un pequeño pipeline llamando a varios programas del paquete **EMBOSS** sobre el mRNA de HTT (`data/NM_002111.gb`):

1. **secret** convierte el mRNA del formato GenBank a FASTA de nucleótidos.
2. **getorf** calcula los ORFs (marcos de lectura abiertos) del mRNA y los traduce a proteína. Se usó `-find 1` (traducir las regiones entre un codón de inicio ATG y el de stop) y `-minsize 300` (300 nucleótidos = 100 aa, para descartar ORFs cortos espurios).
3. El script selecciona el **ORF más largo**, que corresponde a la huntingtina.
4. Descarga la base de datos **PROSITE** (`prosite.dat` + `prosite.doc`) desde el FTP de ExPASy y la indexa con **prosextract**.
5. Finalmente, **patmatmotifs** analiza los dominios/motivos funcionales conocidos de la proteína contra PROSITE y escribe el resultado en `output/ex5_domains.txt`.

```
docker compose run tp python src/ex5_emboss.py
# input: data/NM_002111.gb
# output: output/ex5_orfs.fasta, output/ex5_longest_orf.fasta, output/ex5_domains.txt
```

Resultados

getorf encontró **8 ORFs** de al menos 100 aa. El más largo es la huntingtina:

```
>NM_002111_1 [146 - 9577] Homo sapiens huntingtin (HTT), transcript variant 2, mRNA
Longitud: 3144 aa
```

Este tamaño (3144 aa) coincide con el de la huntingtina humana conocida y con el frame +2 que ya habíamos identificado en la Parte 1.

El análisis de dominios con **patmatmotifs** contra PROSITE encontró **4 motivos funcionales**:

Motivo	Posición (aa)	Qué es
AMIDATION	1532–1535	Sitio de amidación
AMIDATION	2545–2548	Sitio de amidación
LEUCINE_ZIPPER	1446–1467	Patrón "cremallera de leucina"
TYR_PHOSPHO_SITE_2	2716–2723	Sitio de fosforilación de tirosina

Conclusión del ejercicio

Lo más útil de este ejercicio fue ver cómo se pueden encadenar varias herramientas de EMBOSS en un mismo pipeline: a partir del mRNA en GenBank se obtienen los ORFs, se elige automáticamente el más largo y sobre esa proteína se buscan dominios funcionales contra una base de datos externa (PROSITE). Que **getorf** recupere la huntingtina completa de 3144 aa de forma independiente confirma el resultado de la Parte 1 por otro camino. Los motivos PROSITE encontrados (sitios de fosforilación, amidación y una cremallera de leucina) dan una primera pista de las regiones funcionales de la proteína.

10. Ejercicio 6 — Trabajo con Bases de Datos Biológicas

Gen: HTT (Huntingtin) · **Enfermedad:** Enfermedad de Huntington (OMIM #143100) **NCBI Gene ID:** 3064 · **UniProt:** P42858 · **Ensembl:** ENSG00000197386

Datos verificados contra las bases en vivo en junio de 2026. Como las bases se actualizan periódicamente, los conteos podrían variar en el futuro.

a) Gen / proteína de interés — NCBI Gene

Link Entrez Gene: <https://www.ncbi.nlm.nih.gov/gene/3064>

Entramos a la página del gen en NCBI Gene y de ahí sacamos los datos principales. El gen se llama **HTT** (Huntingtin) y tiene el ID **3064**. Está en el **cromosoma 4** (posición 4p16.3) y es un gen bastante grande: ocupa unas 180 kb y está formado por **67 exones**.


Este gen tiene las instrucciones para fabricar una proteína llamada **huntingtina**. Por lo que leímos, la huntingtina aparece sobre todo en el cerebro y es importante para que las neuronas funcionen bien. Cuando el gen tiene un error (una parte de su secuencia, el "CAG", se repite de más), la proteína sale defectuosa y termina dañando a las neuronas, lo que produce la enfermedad de Huntington.

HTT huntingtin [*Homo sapiens* (human)]

Gene ID: 3064, updated on 7-Jun-2026

[Download Datasets](#)

Summary	
Official Symbol	HTT provided by HGNC
Official Full Name	huntingtin provided by HGNC
Primary source	HGNC:HGNC:4851
See related	Ensembl:ENSG00000197386 MIM:613004; AllianceGenome HGNC:4851
Gene type	protein coding
RefSeq status	REVIEWED
Organism	Homo sapiens
Lineage	Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi; Mammalia; Eutheria; Euarchontoglires; Primates; Haplorrhini; Catarrhini; Hominidae; Homo
Also known as	HD; IT15; LOMARS
Summary	Huntingtin is a disease gene linked to Huntington's disease, a neurodegenerative disorder characterized by loss of striatal neurons. This is thought to be caused by an expanded, unstable trinucleotide repeat in the huntingtin gene, which translates as a polyglutamine repeat in the protein product. A fairly broad range of trinucleotide repeats (9-35) has been identified in normal controls, and repeat numbers in excess of 40 have been described as pathological. The huntingtin locus is large, spanning 180 kb and consisting of 67 exons. The huntingtin gene is widely expressed and is required for normal development. It is expressed as 2 alternatively polyadenylated forms displaying different relative abundance in various fetal and adult tissues. The larger transcript is approximately 13.7 kb and is expressed predominantly in adult and fetal brain whereas the smaller transcript of approximately 10.3 kb is more widely expressed. The genetic defect leading to Huntington's disease may not necessarily eliminate transcription, but may confer a new property on the mRNA or alter the function of the protein. One candidate is the huntingtin-associated protein-1, highly expressed in brain, which has increased affinity for huntingtin protein with expanded polyglutamine repeats. This gene contains an upstream open reading frame in the 5' UTR that inhibits expression of the huntingtin gene product through translational repression. [provided by RefSeq, Jul 2016]
Expression	Ubiquitous expression in brain (RPKM 9.1), skin (RPKM 8.2) and 25 other tissues See more
Orthologs	all
Try the new Gene page	
Try the new Transcripts and proteins table	



HomoloGene Now Redirects to NCBI Datasets Gene

A new way to view and download related genes

As [previously announced](#), HomoloGene now automatically redirects to the [NCBI Datasets Gene page](#) giving you easy access to up-to-date sequence and homology data. The NCBI Datasets Gene Table

NCBI Orthologs (el reemplazo de HomoloGene): <https://www.ncbi.nlm.nih.gov/datasets/gene/3064/#orthologs> Acá sí encontramos los datos. NCBI lista **849 genes ortólogos** de HTT, es decir, versiones de este mismo gen repartidas en muchísimas especies distintas.

HTT - huntingtin BETA

[Homo sapiens](#)

Summary Transcripts and proteins Orthologs Gene ontology

Orthologs

Method: NCBI Ortholog i

Selected taxa

Download

Align

Select columns

849 Genes

Rows per page

20

1-20 of 849

<

>

☐	Scientific name	Protein accession	Length (aa)	Architecture	Genomic coordinates	Orientation	Action
☐	Homo sapiens (human)	NP_001375421.1	3,142		NC_000004.12:3074681-3243960 NC_060928.1:3073408-3242718	plus	
☐	Mus musculus (house mouse)	NP_034544.1	3,120		NC_000071.7:34919084-35069878	plus	
☐	Rattus norvegicus (Norway rat)	NP_077333.2	3,120		NC_086032.1:80070456-80219668	minus	

Feedback

Ensembl (Comparative Genomics / orthologues):

https://www.ensembl.org/Homo_sapiens/Gene/Compare/Ortholog?g=ENSG00000197386 Esta base sí está activa.

Comparó el gen HTT contra **199 especies** y encontró que tiene un gen equivalente (ortólogo) en **190 de ellas**:

Tipo de relación	Qué significa	Especies
1:1	un gen humano = un gen en la otra especie	180
1:varios	un gen humano = varios en la otra (duplicaciones)	10
sin ortólogo	no se encontró equivalente	9

Orthologues ?

Download orthologues

Summary of orthologues of this gene [Hide](#)

Click on 'Show details' to display the orthologues for one or more groups of species. Alternatively, click on 'Configure this page' to choose a custom list of species.

Species set	Show details	With 1:1 orthologues	With 1:many orthologues	With many:many orthologues	Without orthologues
Primates (23 species) Humans and other primates	☐	23	0	0	0
Rodents and related species (24 species) Rodents, lagomorphs and tree shrews	☐	23	0	0	1
Laurasiatheria (38 species) Carnivores, ungulates and insectivores	☐	35	1	0	2
Placental Mammals (90 species) All placental mammals	☐	86	1	0	3
Sauropsida (27 species) Birds and Reptiles	☐	26	1	0	0
Fish (65 species) Ray-finned fishes	☐	54	6	0	5
All (199 species) All species, including invertebrates	☒	180	10	0	9

Diferencia entre las bases: HomoloGene era una base vieja y estática, y NCBI ya la discontinuó. Sus dos reemplazos —**NCBI Orthologs** y **Ensembl**— están actualizados y comparan automáticamente contra muchísimas especies. Una aclaración importante: los números no se comparan directamente porque cada base cuenta cosas distintas. NCBI cuenta **genes** (849, contando varias especies y a veces más de un gen por especie), mientras que Ensembl cuenta **especies** (199 comparadas, con ortólogo en 190). Más allá del número exacto, las dos coinciden en lo mismo: HTT aparece en una enorme cantidad de organismos.

Qué tan común es el gen y grupos taxonómicos: el resultado de Ensembl (ortólogo en 190 de 199 especies, casi todos 1:1) muestra que HTT está **muy conservado en todos los vertebrados**. Además, en el Ejercicio 2 (BLAST) habíamos encontrado un homólogo hasta en *Dictyostelium discoideum* (una ameba, 28.8% de identidad), lo que indica que el gen es **muy antiguo**: existe desde mucho antes de los vertebrados y aparece en eucariotas en general, no sólo en animales.

c) Transcriptos y splicing alternativo

Antes que nada, qué es esto en simple: un **gen** es como una receta. A veces, de la misma receta, la célula puede armar **versiones distintas** del plato (cambiando o salteando algunos pasos). Cada versión es un **transcripto**, y esa "edición" de la receta se llama **splicing alternativo**. Acá lo que hicimos fue ver cuántas versiones distintas de HTT figuran en cada base.

NCBI (RefSeq): <https://www.ncbi.nlm.nih.gov/gene/3064> (sección *RefSeq transcripts*) En NCBI encontramos solo **2 transcriptos**: NM_001388492.1 y NM_002111.8 (este último es el que usamos en el TP). Son pocos porque NCBI los **revisa a mano**, así que solo deja los que están bien confirmados.

HTT - huntingtin BETA

Homo sapiens

Summary **Transcripts and proteins** Orthologs Gene ontology

Transcripts and proteins

Download ▾		Select columns	2 Transcripts					
☐	Gene ID	Symbol	Transcript accession	Length (nt)	Protein accession	Length (aa)	Architer	Action
☐	3064	HTT	NM_001388492.1 MANE Select	13,472	NP_001375421.1	3,142		⋮
☐	3064	HTT	NM_002111.8	13,498	NP_002102.4	3,144		⋮

Ensembl: https://www.ensembl.org/Homo_sapiens/Gene/Summary?g=ENSG00000197386 Ensembl, en cambio, lista **24 transcritos** para HTT. Muchos más que NCBI, porque esta base los detecta de forma automática e incluye también versiones más raras o poco usadas.

Human (GRCh38.p14) ▾

Location: 4:3,041,363-3,243,957

Gene: HTT

Gene-based displays

Summary

Splice variants

Transcript comparison

Gene alleles

Sequence

Secondary Structure

Comparative Genomics

Genomic alignments

Gene tree

Gene gain/loss tree

Orthologues

Paralogues

Ontologies

GO: Biological process

GO: Cellular component

GO: Molecular function

Phenotypes

Genetic Variation

Variant table

Variant image

Structural variants

Gene expression

Pathway

Molecular interactions

External references

Supporting evidence

ID History

Gene history

Gene: HTT ENSG00000197386

Description

huntingtin [Source:HGNC Symbol;Acc:HGNC:4851]

Gene Synonyms

HD, IT15

Location

Chromosome 4: 3,041,363-3,243,957 forward strand.
GRCh38: CM000666.2

About this gene

This gene has 24 transcripts ([splice variants](#)), 206 orthologues and is associated with 7 phenotypes

Transcripts

Hide transcript table

Show/hide columns (1 hidden)

Transcript ID	Name	bp	Protein	Biotype	CCDS	UniProt Match	RefSeq Match	Flags
ENST00000355072.11	HTT-201	13472	3142aa	Protein coding	CCDS43205.6	P42858.6	NM_001388492.1.6	MANE Select Ensembl Canonical GENCODE Primary GENCODE Basic
ENST00000681528.2	HTT-223	14037	3089aa	Protein coding		A0A7P0TAC5.6	-	GENCODE Basic
ENST00000680956.2	HTT-222	13947	3056aa	Protein coding		A0A7P0TAT8.6	-	GENCODE Basic APPRIS ALT2
ENST00000118545.1	HTT-224	2229	452aa	Protein coding		-	-	GENCODE Basic
ENST00000509618.1	HTT-205	429	112aa	Protein coding		H0YA07.6	-	TSL:3 CDS 5' incomplete
ENST00000649131.1	HTT-215	289	97aa	Protein coding		A0A3B3ISR3.6	-	CDS 5' and 3' incomplete
ENST00000680360.1	HTT-221	13984	2101aa	Nonsense mediated decay		A0A7P0Z417.6	-	-
ENST00000680239.1	HTT-219	13834	2880aa	Nonsense mediated decay		A0A7P0TAN5.6	-	-
ENST00000650588.1	HTT-217	503	75aa	Nonsense mediated decay		A0A3B3IU25.6	-	CDS 5' incomplete

Base	Nº de transcritos	Cómo los arma
NCBI RefSeq	2	Revisados a mano, alta confianza
Ensembl	24	Automático, capta más variantes

¿Por qué dan números tan distintos? Como nos llamó la atención la diferencia, lo buscamos y encontramos la explicación en un foro de bioinformática ([Biostars](#)): RefSeq (NCBI) es una colección **curada** de transcritos — menos, pero bien confirmados—, mientras que Ensembl es más **inclusiva** e incorpora muchas variantes, incluso algunas con poco respaldo. O sea: NCBI prioriza estar seguro de lo que muestra, y Ensembl prioriza mostrar todo lo posible.

¿Cuáles se expresan y cuál base es más precisa? La versión principal es la que fabrica la huntingtina completa, que es la forma importante. Muchas de las 24 de Ensembl son versiones cortas o poco frecuentes. Por eso **las dos bases sirven para cosas distintas**: NCBI es más confiable (pocas pero seguras, ideal para uso médico), y Ensembl es más completa (muestra toda la variedad posible, aunque algunas sean dudosas). Es la misma diferencia que vimos en el punto b).

d) Interacciones proteína–proteína

Qué es esto en simple: las proteínas no trabajan solas, se "enganchan" con otras para hacer su tarea. Acá miramos con cuántas otras proteínas se relaciona la huntingtina, comparando dos bases: **NCBI Gene** y **UniProt**.

- **NCBI Gene** (<https://www.ncbi.nlm.nih.gov/gene/3064>, sección *Interactions*): nos dio una tabla con **560** interacciones.
- **UniProt** (<https://www.uniprot.org/uniprotkb/P42858/entry#interaction>): nos dio una tabla con **860** interacciones.

Interactions						
Items 1 - 25 of 560 << First < Prev Page 1 of 23 Next > Last >>						
Products	Interactant	Other Gene	Complex	Source	PubS	Description
NM_002111.4	NP_002750.1	EIF2AK2	-	BIND	PubMed	PKR interacts with huntingtin mRNA.
NP_002102.2	NP_005154.1	AKT1	-	BIND	PubMed	Huntingtin is serine-phosphorylated by Akt.
NP_002102.2	NP_150634.1	CASP1	-	BIND	PubMed	Huntingtin interacts with caspase 1. This interaction was modeled on a demonstrated interaction between human huntingtin and caspase 1 from an unspecified species.
NP_002102.2	P42575	CASP2	-	BIND	PubMed	Htt interacts with caspase 2.
NP_002102.2	NP_004337.2	CASP3	-	BIND	PubMed	Huntingtin interacts with caspase 3. This interaction was modeled on a demonstrated interaction between human Huntingtin and caspase 3 from an unspecified species.
NP_002102.2	NP_001217.2	CASP6	-	BIND	PubMed	Htt interacts with caspase 6.
NP_002102.2	NP_203125.1	CASP7	-	BIND	PubMed	Htt interacts with caspase 7.
NP_002102.2	NP_203519.1	CASP8	-	BIND	PubMed	Htt interacts with caspase 8.
NP_002102.2	NP_004371.1	CREBBP	-	BIND	PubMed	CBP interacts with htt. This interaction was modeled on a demonstrated interaction between CBP and htt from unspecified species.
NP_002102.2	NP_004371.1	CREBBP	-	BIND	PubMed	Htt interacts with CBP.
NP_002102.2	NP_001319.1	CTBP1	-	BIND	PubMed	Huntingtin interacts with CTBP.
NP_002102.2	NP_001356.1	DLG4	-	BIND	PubMed	Huntingtin interacts with PSD-95.
NP_002102.2	NP_002077.1	GRB2	-	BIND	PubMed	HDP interacts with Grb2.
NP_002102.2	NP_817084.1	HAP1	-	BIND	PubMed	Huntingtin interacts with HAP1.
NP_002102.2		HAP1	-	BIND	PubMed	Htt interacts with Hap1.
NP_002102.2		HAP1	-	BIND	PubMed	Htt interacts with HAP1. This interaction was modeled on a demonstrated interaction between human Htt

Binary interactions ⁱ				
TYPE	ENTRY 1	ENTRY 2	NUMBER OF EXPERIMENTS	INTACT
All				
BINARY	P42858	A8K3Q9	3	EBI-466029, EBI-10174314
BINARY	P42858	A8K878	21	EBI-466029, EBI-25831303
BINARY	P42858	AAMDC Q9H7C9	3	EBI-466029, EBI-10308705
BINARY	P42858	ABHD17C Q6PCB6	21	EBI-466029, EBI-22011868
BINARY	P42858	ABT1 Q9ULW3	9	EBI-466029, EBI-2602396
BINARY	P42858	ACTB P60709	3	EBI-466029, EBI-353944
BINARY	P42858	ACTG1 P63261	16	EBI-466029, EBI-351292
BINARY	P42858	ACTR1B P42025	3	EBI-466029, EBI-367493
BINARY	P42858	ADIRPOO O15R48	9	EBI-466029, EBI-10827839

O sea, la huntingtina se relaciona con **muchísimas** otras proteínas. Algunas de las más conocidas:

Proteína	Para qué
HAP1	Transporte de cargas dentro de la neurona
HIP1	Ayuda a meter cosas dentro de la célula (endocitosis)
HIP14	Modifica químicamente a la huntingtina

DCTN1

Parte del "motor" que mueve cargas dentro de la célula


¿Hay un patrón? Sí: la mayoría de estas proteínas tienen que ver con **mover cosas de un lado a otro dentro de la neurona** (transporte interno). Eso encaja con la función principal de la huntingtina, que es justamente ayudar en ese transporte.

¿Por qué los números no coinciden (560 vs 860)? Otra vez, como en b) y c): cada base junta los datos de fuentes distintas y con criterios distintos, así que una lista más interacciones que la otra. UniProt llegó a un número más alto (860) que NCBI (560), pero las dos coinciden en lo importante: HTT es una proteína **muy conectada**, lo que muestra que cumple un rol central en la neurona.

e) Gene Ontology (GO): componente, proceso y función


Qué es esto en simple: **Gene Ontology (GO)** es un "etiquetado estándar" que describe cada proteína respondiendo tres preguntas: **dónde está, en qué procesos participa y qué hace**. Sacamos estos datos de la página de UniProt (P42858). El listado completo está en las capturas; acá lo resumimos agrupado por tema.

Dónde está (Componente celular): sobre todo en el **citoplasma** (el interior de la célula) y en sus **vesículas** (las "cajitas" de transporte), también en el **endosoma** y en el **núcleo**.



En qué procesos participa (Proceso biológico): los ~20 términos se agrupan en pocos temas:

- **Desarrollo del sistema nervioso** (neurogénesis, desarrollo del cerebro).
- **Transporte dentro de la célula** (mover vesículas a lo largo de los microtúbulos, transporte en las sinapsis, organización del Golgi).
- **Limpieza/reciclado celular** (autofagia: aggrephagy, lipophagy, mitophagy).
- **Muerte celular programada** (apoptosis) y **señalización** (calcio, cascada CAMKK-AMPK).



Qué hace (Función molecular): principalmente **se une a otras proteínas**. Y casi todas esas proteínas son del **sistema de transporte** de la célula: se une a *beta-tubulina*, *dinactina* y *dineína* (las piezas de los "rieles y motores" que mueven cargas dentro de la neurona), además de unirse a otras proteínas reguladoras (p53, kinasas, proteínas de choque térmico).

ASPECT	TERM
Molecular Function	beta-tubulin binding Source:UniProtKB 1 Publication
Molecular Function	dynactin binding Source:UniProtKB 1 Publication
Molecular Function	dynein intermediate chain binding Source:UniProtKB 1 Publication
Molecular Function	heat shock protein binding Source:CAFA 1 Publication
Molecular Function	identical protein binding Source:InterAct 5 Publications
Molecular Function	kinase binding Source:ParkinsonsUK-UCL 1 Publication
Molecular Function	p53 binding Source:UniProtKB 1 Publication
Molecular Function	phosphoprotein phosphatase activity Source:DictyBase 1 Publication
Molecular Function	profilin binding Source:UniProtKB 1 Publication
Molecular Function	transmembrane transporter binding Source:UniProtKB 1 Publication

En resumen: la huntingtina vive en el **citoplasma y las vesículas**, trabaja sobre todo en el **transporte interno de la neurona y el desarrollo del cerebro**, y lo hace **uniéndose a las proteínas del sistema de transporte**. Las tres categorías de GO cuentan la misma historia que ya veníamos viendo en los puntos anteriores.

f) Vías metabólicas / pathways

Qué es esto en simple: un **pathway** es una "cadena de pasos" donde varias proteínas trabajan juntas para lograr algo en la célula, como una línea de producción. Acá vimos en qué cadenas participa HTT.

KEGG: https://www.genome.jp/dbget-bin/www_bget?hsa:3064 KEGG ubica a HTT en dos pathways, los dos relacionados con la enfermedad:

- **hsa05016 — Huntington disease** (la vía propia de la enfermedad)
- **hsa05022 — Pathways of neurodegeneration** (vía general de enfermedades neurodegenerativas)

Lo interesante es que KEGG además muestra **cómo la huntingtina dañada (mutada) rompe muchas cosas distintas** dentro de la neurona. Algunos ejemplos que lista:

- frena el **transporte de cargas** dentro de la neurona (axonal),
- altera la **lectura de genes** (transcripción: p53, CREB, REST),
- daña las **mitocondrias** (la "central de energía" de la célula),
- desregula la **autofagia** y la **eliminación de basura** celular (proteasoma),
- dispara la **muerte de la neurona** (apoptosis).

Es decir, un solo gen roto termina afectando un montón de procesos a la vez — por eso la enfermedad es tan grave. KEGG también muestra que ya hay **medicamentos** apuntando a este gen (Tominersen, Votoplam), un dato interesante.

 Homo sapiens (human): 3064 Help			
Entry	3064	CDS	T01001
Symbol	HTT, HD, IT15, LOMARS		
Name	(RefSeq) huntingtin isoform 1		
KO	K04533 huntingtin		
Organism	hsa Homo sapiens (human)		
Pathway	hsa05016 Huntington disease hsa05022 Pathways of neurodegeneration - multiple diseases		
Network	nt06461 Huntington disease nt06466 Pathways of neurodegeneration		
Element	N00977 Mutation-caused aberrant Htt to retrograde axonal transport N00979 Mutation-caused aberrant Htt to anterograde axonal transport N00980 Mutation-caused aberrant Htt to REST-mediated transcriptional repression N00981 Mutation-caused aberrant Htt to CREB-mediated transcription N00982 Mutation-caused aberrant Htt to p53-mediated transcription N00983 Mutation-caused aberrant Htt to extrinsic apoptotic pathway N00985 Mutation-caused aberrant Htt to mGluR5-Ca2+ -apoptotic pathway N00986 Mutation-caused aberrant Htt to VGCC-Ca2+ -apoptotic pathway N00987 Mutation-caused aberrant Htt to transport of calcium N00989 Mutation-caused aberrant Htt to electron transfer in Complex II N00991 Mutation-caused aberrant Htt to electron transfer in Complex III N00992 Mutation-caused aberrant Htt to TNF-JNK signaling pathway N00993 Mutation-caused aberrant Htt to autophagy-vesicle nucleation N01061 Mutation-caused aberrant Htt to 26S proteasome-mediated protein degradation		
Disease	H00059 Huntington disease		
Drug target	Tominersen (DG03151): D12012 D12013 Votoplam: D12970		
Brite	KEGG Orthology (KO) [BR: hsa00001] 09160 Human Diseases 09164 Neurodegenerative disease 05016 Huntington disease		

All links
 Disease (3)
 OMIM (3)
 Gene (52)
 RefGene (46)
 NCBI-PROTEINID (1)
 NCBI-Gene (1)
 HGNC (1)
 Ensembl (1)
 RIKEN BRC-DNA (1)
 OC (1)
 Protein sequence (4)
 UniProt (1)
 SWISS-PROT (1)
 RefSeq(pep) (2)
 DNA sequence (24)
 RefSeq(nuc) (2)
 GenBank (11)
 EMBL (11)
 3D Structure (31)
 PDB (31)
 Protein domain (9)
 Pfam (9)
 All databases (123)
[Download RDF](#)

Patrón: todos los pathways apuntan a lo mismo que veníamos viendo en GO e interacciones — **transporte dentro de la neurona, autofagia y neurodegeneración**.

g) Variante genética (dbSNP / ClinVar)

Qué es esto en simple: una **variante** es un "cambio" en el ADN respecto de lo normal. Acá buscamos la variante que causa la enfermedad de Huntington y qué se sabe de ella.

La variante: entramos a **ClinVar** (<https://www.ncbi.nlm.nih.gov/clinvar/?term=HTT%5Bgene%5D>) y, filtrando por *Pathogenic*, encontramos **132 variantes** que causan enfermedad en este gen. La principal —la que causa Huntington— es la **expansión del "CAG"**: en vez de un cambio de una sola letra, lo que pasa es que un pedacito del ADN (las letras CAG) **se repite de más**. En ClinVar es la entrada **Variation ID 409**, clasificada como **Pathogenic** para la enfermedad de Huntington, con el nivel de confianza más alto que da la base (*practice guideline*).

Condition 	Classification  (# of submissions)	Review status 	Last evaluated 	Variation/condition record 
Huntington disease	Pathogenic (3)	★★★★	Jul 31, 2014	RCV000030659.8

Lo interesante de esta variante es que **cuántas veces se repite el CAG decide si te enfermás y qué tan grave:**

Veces que se repite el CAG	Qué pasa
35 o menos	Normal (no te enfermás)
36 a 39	Zona de riesgo (puede o no aparecer)
40 o más	Aparece la enfermedad de Huntington
60 o más	Forma juvenil (empieza en la infancia/adolescencia)

¿A quiénes afecta más? Para esto usamos **MedlinePlus** (la base de divulgación de NCBI que sugiere la consigna). En su sección de frecuencia dice textualmente:

La enfermedad de Huntington afecta a un estimado de 3 a 7 de cada 100.000 personas de ascendencia europea. El trastorno parece ser menos común en algunas otras poblaciones, incluidas las personas de ascendencia japonesa, china y africana.

Es decir, la enfermedad es claramente **más frecuente en personas de ascendencia europea** y menos común en personas de ascendencia japonesa, china y africana.

Frequency 

Huntington's disease affects an estimated 3 to 7 per 100,000 people of European ancestry. The disorder appears to be less common in some other populations, including people of Japanese, Chinese, and African descent.

Fuentes del Ejercicio 6

- [NCBI Gene 3064 \(HTT\)](#) · [OMIM #143100](#) · [OMIM *613004 \(HTT\)](#)
- [Ensembl ENSG00000197386](#)
- [UniProt P42858](#) · [GeneCards HTT](#)
- [KEGG hsa05016 — Huntington disease](#) · [ClinVar Variation ID 409](#)
- [MedlinePlus — Huntington disease](#) · [Biostars — RefSeq vs Ensembl](#)
- [NCBI Insights — HomoloGene redirige a NCBI Datasets/Gene \(2024\)](#)
- [Wikipedia — Huntingtin](#)

Anexo — Cómo ejecutar los scripts

Requisitos: Docker Desktop instalado y corriendo.

```
# Clonar el repositorio
git clone https://github.com/hhrib/tp-bioinformatica-2026

# Entrar al contenedor
docker compose run tp bash

# Parte 1
python src/ex1_reading_frames.py           # Genera output/orfs.fasta
python src/ex2_blast.py                   # Genera output/blast.out
python src/ex3_msa.py                     # Descarga secuencias para el MSA

# Parte 2
python src/ex4_blast_parser.py "Mus musculus" # Genera output/ex4_hits.fasta
python src/ex5_emboss.py                  # Genera output/ex5_*.fasta y
ex5_domains.txt
```

Los archivos de input (data/NM_002111.gb) y output (output/) se encuentran en el repositorio.