



UTN.BA

Bioinformática - K5061

Integrantes – Año 2026

Nombre	E-Mail
Tomás Guillermo León	tleon@frba.utn.edu.ar
Gustavo Di Peppe	gdipeppe@frba.utn.edu.ar
Alejo Gurfein	agurfein@frba.utn.edu.ar
Hernán Hrib	hhrib@frba.utn.edu.ar

Profesor a cargo del curso: Patricio Yankilevich

Trabajo Práctico Parte 2 — Informe

Introducción a la Bioinformática — UTN FRBA Fecha de entrega: 26 de junio de 2026

Esta segunda parte continúa el trabajo sobre el gen **HTT** (Huntingtin) y la enfermedad de Huntington iniciado en la Parte 1. Acá se desarrollan los ejercicios 4 (parser de la salida de BLAST), 5 (análisis con EMBOSS) y 6 (trabajo con bases de datos biológicas). El ambiente de trabajo es el mismo de la Parte 1: Python 3.11 con BioPython, EMBOSS y BLAST+ dentro de un contenedor Docker, con el código versionado en Git.

1. Ejercicio 4 — Parser de la salida de BLAST

Descripción

Se desarrolló el script `src/ex4_blast_parser.py`, que toma como entrada el reporte `output/blast.out` generado en el Ejercicio 2 y un **Pattern** pasado como parámetro por línea de comandos (por defecto `"Mus musculus"`, como en el ejemplo de la consigna). El script recorre el reporte e identifica los hits cuya descripción contiene ese Pattern, de forma **case-insensitive** (para que `"mus musculus"` y `"Mus musculus"` coincidan).

Para distinguir las filas de hit de las líneas decorativas del reporte se usa una expresión regular que detecta el **ACCESSION** al inicio de cada fila (formato tipo `P42859.2`). Además, mientras recorre el archivo, el script va guardando el frame actual (`Frame +2`, etc.) para poder indicar en qué marco de lectura apareció cada hit.

Punto extra: para cada hit que coincide con el Pattern, el script extrae su **ACCESSION** y descarga la secuencia completa de la proteína en formato FASTA desde NCBI usando `Bio.Entrez` (el equivalente en BioPython al módulo `Bio::DB::GenBank` de BioPerl que menciona la consigna), y la escribe a `output/ex4_hits.fasta`.

```
docker compose run tp python src/ex4_blast_parser.py "Mus musculus"
# input:  output/blast.out + Pattern
# output: output/ex4_hits.fasta
```

Resultados

Ejecutando con el Pattern `"Mus musculus"` sobre el `blast.out` del Ejercicio 2, el script encontró **1 hit** que coincide:

Frame	Accession	Descripción
+2	P42859.2	Huntingtin — <i>Mus musculus</i> (ratón)

A continuación descargó la secuencia completa de ese hit desde NCBI y la guardó en `output/ex4_hits.fasta`:

```
>sp|P42859.2|HD_MOUSE RecName: Full=Huntingtin; AltName: Full=Huntington
disease protein homolog; Short=HD protein homolog; ...
```

Si se ejecuta con otro Pattern (por ejemplo `"Rattus"` o `"Takifugu"`) el script devuelve los hits correspondientes a esa otra especie, lo que confirma que el filtro funciona de forma genérica.

Conclusión del ejercicio

El ejercicio muestra cómo procesar de forma programática la salida de una herramienta como BLAST en lugar de leerla a mano. Lo más interesante fue el punto extra: con solo el **ACCESSION** del hit se puede recuperar automáticamente la secuencia original completa desde NCBI, encadenando el resultado del BLAST con una nueva

consulta a la base de datos. Esto deja todo listo para análisis posteriores (por ejemplo, un alineamiento) sin pasos manuales.

2. Ejercicio 5 — EMBOSS (ORFs y dominios PROSITE)

Descripción

Se desarrolló el script `src/ex5_emboss.py`, que arma un pequeño pipeline llamando a varios programas del paquete **EMBOSS** sobre el mRNA de HTT (`data/NM_002111.gb`):

1. `seqret` convierte el mRNA del formato GenBank a FASTA de nucleótidos.
2. `getorf` calcula los ORFs (marcos de lectura abiertos) del mRNA y los traduce a proteína. Se usó `-find 1` (traducir las regiones entre un codón de inicio ATG y el de stop) y `-minsize 300` (300 nucleótidos = 100 aa, para descartar ORFs cortos espurios).
3. El script selecciona el **ORF más largo**, que corresponde a la huntingtina.
4. Descarga la base de datos **PROSITE** (`prosite.dat` + `prosite.doc`) desde el FTP de ExPASy y la indexa con `prosextract`.
5. Finalmente, `patmatmotifs` analiza los dominios/motivos funcionales conocidos de la proteína contra PROSITE y escribe el resultado en `output/ex5_domains.txt`.

```
docker compose run tp python src/ex5_emboss.py
# input: data/NM_002111.gb
# output: output/ex5_orfs.fasta, output/ex5_longest_orf.fasta, output/ex5_domains.txt
```

Resultados

`getorf` encontró **8 ORFs** de al menos 100 aa. El más largo es la huntingtina:

```
>NM_002111_1 [146 - 9577] Homo sapiens huntingtin (HTT), transcript variant 2, mRNA
Longitud: 3144 aa
```

Este tamaño (3144 aa) coincide con el de la huntingtina humana conocida y con el frame +2 que ya habíamos identificado en la Parte 1.

El análisis de dominios con `patmatmotifs` contra PROSITE encontró **4 motivos funcionales**:

Motivo	Posición (aa)	Qué es
AMIDATION	1532–1535	Sitio de amidación
AMIDATION	2545–2548	Sitio de amidación
LEUCINE_ZIPPER	1446–1467	Patrón "cremallera de leucina"
TYR_PHOSPHO_SITE_2	2716–2723	Sitio de fosforilación de tirosina

Conclusión del ejercicio

Lo más útil de este ejercicio fue ver cómo se pueden encadenar varias herramientas de EMBOSS en un mismo pipeline: a partir del mRNA en GenBank se obtienen los ORFs, se elige automáticamente el más largo y sobre esa proteína se buscan dominios funcionales contra una base de datos externa (PROSITE). Que `getorf` recupere la huntingtina completa de 3144 aa de forma independiente confirma el resultado de la Parte 1 por otro camino. Los

motivos PROSITE encontrados (sitios de fosforilación, amidación y una cremallera de leucina) dan una primera pista de las regiones funcionales de la proteína.

3. Ejercicio 6 — Trabajo con Bases de Datos Biológicas

Gen: HTT (Huntingtin) · **Enfermedad:** Enfermedad de Huntington (OMIM #143100) **NCBI Gene ID:** 3064 · **UniProt:** P42858 · **Ensembl:** ENSG00000197386

Datos verificados contra las bases en vivo en junio de 2026. Como las bases se actualizan periódicamente, los conteos podrían variar en el futuro.

a) Gen / proteína de interés — NCBI Gene

Link Entrez Gene: <https://www.ncbi.nlm.nih.gov/gene/3064>

Entramos a la página del gen en NCBI Gene y de ahí sacamos los datos principales. El gen se llama **HTT** (Huntingtin) y tiene el ID **3064**. Está en el **cromosoma 4** (posición 4p16.3) y es un gen bastante grande: ocupa unas 180 kb y está formado por **67 exones**.

Este gen tiene las instrucciones para fabricar una proteína llamada **huntingtina**. Por lo que leímos, la huntingtina aparece sobre todo en el cerebro y es importante para que las neuronas funcionen bien. Cuando el gen tiene un error (una parte de su secuencia, el "CAG", se repite de más), la proteína sale defectuosa y termina dañando a las neuronas, lo que produce la enfermedad de Huntington.

HTT huntingtin [*Homo sapiens* (human)]

Gene ID: 3064, updated on 7-Jun-2026

[Download Datasets](#)

Summary

Official Symbol

HTT provided by HGNC

Official Full Name

huntingtin provided by HGNC

Primary source

[HGNC:HGNC:4851](#)

See related

[Ensembl:ENSG00000197386](#) [MIM:613004](#) [AllianceGenome:HGNC:4851](#)

Gene type

protein coding

RefSeq status

REVIEWED

Organism

[Homo sapiens](#)

Lineage

Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi; Mammalia; Eutheria; Euarchontoglires; Primates; Haplorrhini; Catarrhini; Hominidae; Homo

Also known as

HD; IT15; LOMARS

Summary

Huntingtin is a disease gene linked to Huntington's disease, a neurodegenerative disorder characterized by loss of striatal neurons. This is thought to be caused by an expanded, unstable trinucleotide repeat in the huntingtin gene, which translates as a polyglutamine repeat in the protein product. A fairly broad range of trinucleotide repeats (9-35) has been identified in normal controls, and repeat numbers in excess of 40 have been described as pathological. The huntingtin locus is large, spanning 180 kb and consisting of 67 exons. The huntingtin gene is widely expressed and is required for normal development. It is expressed as 2 alternatively polyadenylated forms displaying different relative abundance in various fetal and adult tissues. The larger transcript is approximately 13.7 kb and is expressed predominantly in adult and fetal brain whereas the smaller transcript of approximately 10.3 kb is more widely expressed. The genetic defect leading to Huntington's disease may not necessarily eliminate transcription, but may confer a new property on the mRNA or alter the function of the protein. One candidate is the huntingtin-associated protein-1, highly expressed in brain, which has increased affinity for huntingtin protein with expanded polyglutamine repeats. This gene contains an upstream open reading frame in the 5' UTR that inhibits expression of the huntingtin gene product through translational repression. [provided by RefSeq, Jul 2016]

Expression

Ubiquitous expression in brain (RPKM 9.1), skin (RPKM 8.2) and 25 other tissues [See more](#)

Orthologs

[all](#)

Try the new

[Gene page](#)

Try the new

[Transcripts and proteins table](#)

Genomic context

Location: 4p16.3 See HTT in [Genome Data Viewer](#)


Exon count: 67

Annotation release	Status	Assembly	Chr	Location
RS_2025_08	current	GRCh38.p14 (GCF_000001405.40)	4	NC_000004.12 (3074681..3243960)
RS_2025_08	current	T2T-CHM13v2.0 (GCF_009914755.1)	4	NC_060928.1 (3073408..3242718)
RS_2024_09	previous assembly	GRCh37.p13 (GCF_000001405.25)	4	NC_000004.11 (3076408..3245687)

Chromosome 4 - NC_000004.12

[30444101 ▶ | ◀ 30439913]

LOC129992184 ◀ LOC129661228 ◀ LOC127398092 ◀ LOC129992119 ▶
 LOC129992101 ▶ LOC129992110 ▶ LOC129992199 ▶
 RNU6-204P ◀ HTT ▶ RNU7-33P ▶
 LOC129992102 ▶ LOC112939958 ▶ LOC129992111 ▶
 LOC129992104 ▶ LOC127398091 ▶ LOC127398097 ▶
 LOC129992103 ▶ LOC127398093 ▶
 LOC104661479 ▶ LOC127398094 ▶
 LOC129929627 ▶ LOC129661221 ▶
 LOC129992105 ▶ LOC127398095 ▶
 LOC129992106 ▶ LOC127398096 ▶
 LOC129992107 ▶ RNU7-33P ▶
 HTT ◀ RNU7-33P ▶
 LOC129661222 ▶
 LOC129992112 ▶
 LOC129992113 ▶
 LOC127398098 ▶
 LOC127398099 ▶
 LOC10206945 ▶



HomoloGene Now Redirects to NCBI Datasets Gene

A new way to view and download related genes

As [previously announced](#), HomoloGene now automatically redirects to the [NCBI Datasets Gene page](#) giving you easy access to up-to-date sequence and homology data. The NCBI Datasets Gene Table

NCBI Orthologs (el reemplazo de HomoloGene): <https://www.ncbi.nlm.nih.gov/datasets/gene/3064/#orthologs> Acá sí encontramos los datos. NCBI lista **849 genes ortólogos** de HTT, es decir, versiones de este mismo gen repartidas en muchísimas especies distintas.

HTT - huntingtin BETA

[Homo sapiens](#)

[Summary](#) [Transcripts and proteins](#) [Orthologs](#) [Gene ontology](#)

Orthologs

Method: NCBI Ortholog i

Selected taxa

Download

Align

Select columns

849 Genes

Rows per page

20

1-20 of 849

<

>

☐	Scientific name	Protein accession	Length (aa)	Architecture	Genomic coordinates	Orientation	Action
☐	Homo sapiens (human)	NP_001375421.1	3,142		NC_000004.12:3074681-3243960 NC_060928.1:3073408-3242718	plus	
☐	Mus musculus (house mouse)	NP_034544.1	3,120		NC_000071.7:34919084-35069878	plus	
☐	Rattus norvegicus (Norway rat)	NP_077333.2	3,120		NC_086032.1:80070456-80219668	minus	

Feedback

Ensembl (Comparative Genomics / orthologues):

https://www.ensembl.org/Homo_sapiens/Gene/Compare/Ortholog?g=ENSG00000197386 Esta base sí está activa.

Comparó el gen HTT contra **199 especies** y encontró que tiene un gen equivalente (ortólogo) en **190 de ellas**:

Tipo de relación	Qué significa	Especies
1:1	un gen humano = un gen en la otra especie	180
1:varios	un gen humano = varios en la otra (duplicaciones)	10
sin ortólogo	no se encontró equivalente	9

Orthologues ?

Download orthologues

Summary of orthologues of this gene [Hide](#)

Click on 'Show details' to display the orthologues for one or more groups of species. Alternatively, click on 'Configure this page' to choose a custom list of species.

Species set	Show details	With 1:1 orthologues	With 1:many orthologues	With many:many orthologues	Without orthologues
Primates (23 species) Humans and other primates	☐	23	0	0	0
Rodents and related species (24 species) Rodents, lagomorphs and tree shrews	☐	23	0	0	1
Laurasiatheria (38 species) Carnivores, ungulates and insectivores	☐	35	1	0	2
Placental Mammals (90 species) All placental mammals	☐	86	1	0	3
Sauropsida (27 species) Birds and Reptiles	☐	26	1	0	0
Fish (65 species) Ray-finned fishes	☐	54	6	0	5
All (199 species) All species, including invertebrates	☒	180	10	0	9

Diferencia entre las bases: HomoloGene era una base vieja y estática, y NCBI ya la discontinuó. Sus dos reemplazos —**NCBI Orthologs** y **Ensembl**— están actualizados y comparan automáticamente contra muchísimas especies. Una aclaración importante: los números no se comparan directamente porque cada base cuenta cosas distintas. NCBI cuenta **genes** (849, contando varias especies y a veces más de un gen por especie), mientras que Ensembl cuenta **especies** (199 comparadas, con ortólogo en 190). Más allá del número exacto, las dos coinciden en lo mismo: HTT aparece en una enorme cantidad de organismos.

Qué tan común es el gen y grupos taxonómicos: el resultado de Ensembl (ortólogo en 190 de 199 especies, casi todos 1:1) muestra que HTT está **muy conservado en todos los vertebrados**. Además, en el Ejercicio 2 (BLAST) habíamos encontrado un homólogo hasta en *Dictyostelium discoideum* (una ameba, 28.8% de identidad), lo que indica que el gen es **muy antiguo**: existe desde mucho antes de los vertebrados y aparece en eucariotas en general, no sólo en animales.

c) Transcriptos y splicing alternativo

Antes que nada, qué es esto en simple: un **gen** es como una receta. A veces, de la misma receta, la célula puede armar **versiones distintas** del plato (cambiando o salteando algunos pasos). Cada versión es un **transcripto**, y esa "edición" de la receta se llama **splicing alternativo**. Acá lo que hicimos fue ver cuántas versiones distintas de HTT figuran en cada base.

NCBI (RefSeq): <https://www.ncbi.nlm.nih.gov/gene/3064> (sección *RefSeq transcripts*) En NCBI encontramos solo **2 transcriptos**: NM_001388492.1 y NM_002111.8 (este último es el que usamos en el TP). Son pocos porque NCBI los **revisa a mano**, así que solo deja los que están bien confirmados.

HTT - huntingtin BETA

Homo sapiens

Summary **Transcripts and proteins** Orthologs Gene ontology

Transcripts and proteins

Download ▾		Select columns	2 Transcripts					
☐	Gene ID	Symbol	Transcript accession	Length (nt)	Protein accession	Length (aa)	Architer	Action
☐	3064	HTT	NM_001388492.1 MANE Select	13,472	NP_001375421.1	3,142		⋮
☐	3064	HTT	NM_002111.8	13,498	NP_002102.4	3,144		⋮

Ensembl: https://www.ensembl.org/Homo_sapiens/Gene/Summary?g=ENSG00000197386 Ensembl, en cambio, lista **24 transcritos** para HTT. Muchos más que NCBI, porque esta base los detecta de forma automática e incluye también versiones más raras o poco usadas.

Human (GRCh38.p14) ▾

Location: 4:3,041,363-3,243,957

Gene: HTT

Gene-based displays

Summary

Splice variants

Transcript comparison

Gene alleles

Sequence

Secondary Structure

Comparative Genomics

Genomic alignments

Gene tree

Gene gain/loss tree

Orthologues

Paralogues

Ontologies

GO: Biological process

GO: Cellular component

GO: Molecular function

Phenotypes

Genetic Variation

Variant table

Variant image

Structural variants

Gene expression

Pathway

Molecular interactions

External references

Supporting evidence

ID History

Gene history

Gene: HTT ENSG00000197386

Description

huntingtin [Source:HGNC Symbol;Acc:HGNC:48516]

Gene Synonyms

HD, IT15

Location

Chromosome 4: 3,041,363-3,243,957 forward strand.
GRCh38: CM000666.2

About this gene

This gene has 24 transcripts ([splice variants](#)), 206 orthologues and is associated with 7 phenotypes

Transcripts

Hide transcript table

Show/hide columns (1 hidden)

Transcript ID	Name	bp	Protein	Biotype	CCDS	UniProt Match	RefSeq Match	Flags
ENST00000355072.11	HTT-201	13472	3142aa	Protein coding	CCDS43206.6	P42858.6	NM_001388492.1.6	MANE Select Ensembl Canonical GENCODE Primary GENCODE Basic
ENST00000681528.2	HTT-223	14037	3086aa	Protein coding		A0A7P0TAC5.6	-	GENCODE Basic
ENST00000680956.2	HTT-222	13947	3056aa	Protein coding		A0A7P0TAT8.6	-	GENCODE Basic APPRIS ALT2
ENST00000118545.1	HTT-224	2229	452aa	Protein coding		-	-	GENCODE Basic
ENST00000509618.1	HTT-205	429	112aa	Protein coding		H0YA07.6	-	TSL:3 CDS 5' incomplete
ENST00000649131.1	HTT-215	289	97aa	Protein coding		A0A3B3ISR3.6	-	CDS 5' and 3' incomplete
ENST00000680360.1	HTT-221	13984	2101aa	Nonsense mediated decay		A0A7P0Z417.6	-	-
ENST00000680239.1	HTT-219	13834	2880aa	Nonsense mediated decay		A0A7P0TAN5.6	-	-
ENST00000650588.1	HTT-217	503	75aa	Nonsense mediated decay		A0A3B3IU25.6	-	CDS 5' incomplete

Base	Nº de transcritos	Cómo los arma
NCBI RefSeq	2	Revisados a mano, alta confianza
Ensembl	24	Automático, capta más variantes

¿Por qué dan números tan distintos? Como nos llamó la atención la diferencia, lo buscamos y encontramos la explicación en un foro de bioinformática ([Biostars](#)): RefSeq (NCBI) es una colección **curada** de transcritos — menos, pero bien confirmados—, mientras que Ensembl es más **inclusiva** e incorpora muchas variantes, incluso algunas con poco respaldo. O sea: NCBI prioriza estar seguro de lo que muestra, y Ensembl prioriza mostrar todo lo posible.

¿Cuáles se expresan y cuál base es más precisa? La versión principal es la que fabrica la huntingtina completa, que es la forma importante. Muchas de las 24 de Ensembl son versiones cortas o poco frecuentes. Por eso **las dos bases sirven para cosas distintas**: NCBI es más confiable (pocas pero seguras, ideal para uso médico), y Ensembl es más completa (muestra toda la variedad posible, aunque algunas sean dudosas). Es la misma diferencia que vimos en el punto b).

d) Interacciones proteína–proteína

Qué es esto en simple: las proteínas no trabajan solas, se "enganchan" con otras para hacer su tarea. Acá miramos con cuántas otras proteínas se relaciona la huntingtina, comparando dos bases: **NCBI Gene** y **UniProt**.

- **NCBI Gene** (<https://www.ncbi.nlm.nih.gov/gene/3064>, sección *Interactions*): nos dio una tabla con **560** interacciones.
- **UniProt** (<https://www.uniprot.org/uniprotkb/P42858/entry#interaction>): nos dio una tabla con **860** interacciones.

Interactions						
Items 1 - 25 of 560 << First < Prev Page 1 of 23 Next > Last >>						
Products	Interactant	Other Gene	Complex	Source	PubS	Description
NM_002111.4	NP_002750.1	EIF2AK2	-	BIND	PubMed	PKR interacts with huntingtin mRNA.
NP_002102.2	NP_005154.1	AKT1	-	BIND	PubMed	Huntingtin is serine-phosphorylated by Akt.
NP_002102.2	NP_150634.1	CASP1	-	BIND	PubMed	Huntingtin interacts with caspase 1. This interaction was modeled on a demonstrated interaction between human huntingtin and caspase 1 from an unspecified species.
NP_002102.2	P42575	CASP2	-	BIND	PubMed	Htt interacts with caspase 2.
NP_002102.2	NP_004337.2	CASP3	-	BIND	PubMed	Huntingtin interacts with caspase 3. This interaction was modeled on a demonstrated interaction between human Huntingtin and caspase 3 from an unspecified species.
NP_002102.2	NP_001217.2	CASP6	-	BIND	PubMed	Htt interacts with caspase 6.
NP_002102.2	NP_203125.1	CASP7	-	BIND	PubMed	Htt interacts with caspase 7.
NP_002102.2	NP_203519.1	CASP8	-	BIND	PubMed	Htt interacts with caspase 8.
NP_002102.2	NP_004371.1	CREBBP	-	BIND	PubMed	CBP interacts with htt. This interaction was modeled on a demonstrated interaction between CBP and htt from unspecified species.
NP_002102.2	NP_004371.1	CREBBP	-	BIND	PubMed	Htt interacts with CBP.
NP_002102.2	NP_001319.1	CTBP1	-	BIND	PubMed	Huntingtin interacts with CTBP.
NP_002102.2	NP_001356.1	DLG4	-	BIND	PubMed	Huntingtin interacts with PSD-95.
NP_002102.2	NP_002077.1	GRB2	-	BIND	PubMed	HDP interacts with Grb2.
NP_002102.2	NP_817084.1	HAP1	-	BIND	PubMed	Huntingtin interacts with HAP1.
NP_002102.2		HAP1	-	BIND	PubMed	Htt interacts with Hap1.
NP_002102.2		HAP1	-	BIND	PubMed	Htt interacts with HAP1. This interaction was modeled on a demonstrated interaction between human Htt

Binary interactions ⁱ				
TYPE	ENTRY 1	ENTRY 2	NUMBER OF EXPERIMENTS	INTACT
All				
BINARY	P42858	A8K3Q9	3	EBI-466029, EBI-10174314
BINARY	P42858	A8K878	21	EBI-466029, EBI-25831303
BINARY	P42858	AAMDC Q9H7C9	3	EBI-466029, EBI-10308705
BINARY	P42858	ABHD17C Q6PCB6	21	EBI-466029, EBI-22011868
BINARY	P42858	ABT1 Q9ULW3	9	EBI-466029, EBI-2602396
BINARY	P42858	ACTB P60709	3	EBI-466029, EBI-353944
BINARY	P42858	ACTG1 P63261	16	EBI-466029, EBI-351292
BINARY	P42858	ACTR1B P42025	3	EBI-466029, EBI-367493
BINARY	P42858	ADIRPOO O15R48	9	EBI-466029, EBI-10827839

O sea, la huntingtina se relaciona con **muchísimas** otras proteínas. Algunas de las más conocidas:

Proteína	Para qué
HAP1	Transporte de cargas dentro de la neurona
HIP1	Ayuda a meter cosas dentro de la célula (endocitosis)
HIP14	Modifica químicamente a la huntingtina

DCTN1

Parte del "motor" que mueve cargas dentro de la célula


¿Hay un patrón? Sí: la mayoría de estas proteínas tienen que ver con **mover cosas de un lado a otro dentro de la neurona** (transporte interno). Eso encaja con la función principal de la huntingtina, que es justamente ayudar en ese transporte.

¿Por qué los números no coinciden (560 vs 860)? Otra vez, como en b) y c): cada base junta los datos de fuentes distintas y con criterios distintos, así que una lista más interacciones que la otra. UniProt llegó a un número más alto (860) que NCBI (560), pero las dos coinciden en lo importante: HTT es una proteína **muy conectada**, lo que muestra que cumple un rol central en la neurona.

e) Gene Ontology (GO): componente, proceso y función


Qué es esto en simple: **Gene Ontology (GO)** es un "etiquetado estándar" que describe cada proteína respondiendo tres preguntas: **dónde está, en qué procesos participa y qué hace**. Sacamos estos datos de la página de UniProt (P42858). El listado completo está en las capturas; acá lo resumimos agrupado por tema.

Dónde está (Componente celular): sobre todo en el **citoplasma** (el interior de la célula) y en sus **vesículas** (las "cajitas" de transporte), también en el **endosoma** y en el **núcleo**.



En qué procesos participa (Proceso biológico): los ~20 términos se agrupan en pocos temas:

- **Desarrollo del sistema nervioso** (neurogénesis, desarrollo del cerebro).
- **Transporte dentro de la célula** (mover vesículas a lo largo de los microtúbulos, transporte en las sinapsis, organización del Golgi).
- **Limpieza/reciclado celular** (autofagia: aggrephagy, lipophagy, mitophagy).
- **Muerte celular programada** (apoptosis) y **señalización** (calcio, cascada CAMKK-AMPK).



Qué hace (Función molecular): principalmente **se une a otras proteínas**. Y casi todas esas proteínas son del **sistema de transporte** de la célula: se une a *beta-tubulina*, *dinactina* y *dineína* (las piezas de los "rieles y motores" que mueven cargas dentro de la neurona), además de unirse a otras proteínas reguladoras (p53, kinasas, proteínas de choque térmico).

ASPECT	TERM
Molecular Function	beta-tubulin binding Source:UniProtKB 1 Publication
Molecular Function	dynactin binding Source:UniProtKB 1 Publication
Molecular Function	dynein intermediate chain binding Source:UniProtKB 1 Publication
Molecular Function	heat shock protein binding Source:CAFA 1 Publication
Molecular Function	identical protein binding Source:InterAct 5 Publications
Molecular Function	kinase binding Source:ParkinsonsUK-UCL 1 Publication
Molecular Function	p53 binding Source:UniProtKB 1 Publication
Molecular Function	phosphoprotein phosphatase activity Source:DictyBase 1 Publication
Molecular Function	profilin binding Source:UniProtKB 1 Publication
Molecular Function	transmembrane transporter binding Source:UniProtKB 1 Publication

En resumen: la huntingtina vive en el **citoplasma y las vesículas**, trabaja sobre todo en el **transporte interno de la neurona y el desarrollo del cerebro**, y lo hace **uniéndose a las proteínas del sistema de transporte**. Las tres categorías de GO cuentan la misma historia que ya veníamos viendo en los puntos anteriores.

f) Vías metabólicas / pathways

Qué es esto en simple: un **pathway** es una "cadena de pasos" donde varias proteínas trabajan juntas para lograr algo en la célula, como una línea de producción. Acá vimos en qué cadenas participa HTT.

KEGG: https://www.genome.jp/dbget-bin/www_bget?hsa:3064 KEGG ubica a HTT en dos pathways, los dos relacionados con la enfermedad:

- **hsa05016 — Huntington disease** (la vía propia de la enfermedad)
- **hsa05022 — Pathways of neurodegeneration** (vía general de enfermedades neurodegenerativas)

Lo interesante es que KEGG además muestra **cómo la huntingtina dañada (mutada) rompe muchas cosas distintas** dentro de la neurona. Algunos ejemplos que lista:

- frena el **transporte de cargas** dentro de la neurona (axonal),
- altera la **lectura de genes** (transcripción: p53, CREB, REST),
- daña las **mitocondrias** (la "central de energía" de la célula),
- desregula la **autofagia** y la **eliminación de basura** celular (proteasoma),
- dispara la **muerte de la neurona** (apoptosis).

Es decir, un solo gen roto termina afectando un montón de procesos a la vez — por eso la enfermedad es tan grave. KEGG también muestra que ya hay **medicamentos** apuntando a este gen (Tominersen, Votoplam), un dato interesante.

 Homo sapiens (human): 3064 Help			
Entry	3064	CDS	T01001
Symbol	HTT, HD, IT15, LOMARS		
Name	(RefSeq) huntingtin isoform 1		
KO	K04533 huntingtin		
Organism	hsa Homo sapiens (human)		
Pathway	hsa05016 Huntington disease hsa05022 Pathways of neurodegeneration - multiple diseases		
Network	nt06461 Huntington disease nt06466 Pathways of neurodegeneration		
Element	N00977 Mutation-caused aberrant Htt to retrograde axonal transport N00979 Mutation-caused aberrant Htt to anterograde axonal transport N00980 Mutation-caused aberrant Htt to REST-mediated transcriptional repression N00981 Mutation-caused aberrant Htt to CREB-mediated transcription N00982 Mutation-caused aberrant Htt to p53-mediated transcription N00983 Mutation-caused aberrant Htt to extrinsic apoptotic pathway N00985 Mutation-caused aberrant Htt to mGluR5-Ca2+ -apoptotic pathway N00986 Mutation-caused aberrant Htt to VGCC-Ca2+ -apoptotic pathway N00987 Mutation-caused aberrant Htt to transport of calcium N00989 Mutation-caused aberrant Htt to electron transfer in Complex II N00991 Mutation-caused aberrant Htt to electron transfer in Complex III N00992 Mutation-caused aberrant Htt to TNF-JNK signaling pathway N00993 Mutation-caused aberrant Htt to autophagy-vesicle nucleation N01061 Mutation-caused aberrant Htt to 26S proteasome-mediated protein degradation		
Disease	H00059 Huntington disease		
Drug target	Tominersen (DG03151): D12012 D12013 Votoplam: D12970		
Brite	KEGG Orthology (KO) [BR: hsa00001] 09160 Human Diseases 09164 Neurodegenerative disease 05016 Huntington disease		

All links
 Disease (3)
 OMIM (3)
 Gene (52)
 RefGene (46)
 NCBI-PROTEINID (1)
 NCBI-Gene (1)
 HGNC (1)
 Ensembl (1)
 RIKEN BRC-DNA (1)
 OC (1)
 Protein sequence (4)
 UniProt (1)
 SWISS-PROT (1)
 RefSeq(pep) (2)
 DNA sequence (24)
 RefSeq(nuc) (2)
 GenBank (11)
 EMBL (11)
 3D Structure (31)
 PDB (31)
 Protein domain (9)
 Pfam (9)
 All databases (123)
[Download RDF](#)

Patrón: todos los pathways apuntan a lo mismo que veníamos viendo en GO e interacciones — **transporte dentro de la neurona, autofagia y neurodegeneración**.

g) Variante genética (dbSNP / ClinVar)

Qué es esto en simple: una **variante** es un "cambio" en el ADN respecto de lo normal. Acá buscamos la variante que causa la enfermedad de Huntington y qué se sabe de ella.

La variante: entramos a **ClinVar** (<https://www.ncbi.nlm.nih.gov/clinvar/?term=HTT%5Bgene%5D>) y, filtrando por *Pathogenic*, encontramos **132 variantes** que causan enfermedad en este gen. La principal —la que causa Huntington— es la **expansión del "CAG"**: en vez de un cambio de una sola letra, lo que pasa es que un pedacito del ADN (las letras CAG) **se repite de más**. En ClinVar es la entrada **Variation ID 409**, clasificada como **Pathogenic** para la enfermedad de Huntington, con el nivel de confianza más alto que da la base (*practice guideline*).

Condition 	Classification  (# of submissions)	Review status 	Last evaluated 	Variation/condition record 
Huntington disease	Pathogenic (3)	★★★★	Jul 31, 2014	RCV000030659.8

Lo interesante de esta variante es que **cuántas veces se repite el CAG decide si te enfermás y qué tan grave:**

Veces que se repite el CAG	Qué pasa
35 o menos	Normal (no te enfermás)
36 a 39	Zona de riesgo (puede o no aparecer)
40 o más	Aparece la enfermedad de Huntington
60 o más	Forma juvenil (empieza en la infancia/adolescencia)

¿A quiénes afecta más? Para esto usamos **MedlinePlus** (la base de divulgación de NCBI que sugiere la consigna). En su sección de frecuencia dice textualmente:

La enfermedad de Huntington afecta a un estimado de 3 a 7 de cada 100.000 personas de ascendencia europea. El trastorno parece ser menos común en algunas otras poblaciones, incluidas las personas de ascendencia japonesa, china y africana.

Es decir, la enfermedad es claramente **más frecuente en personas de ascendencia europea** y menos común en personas de ascendencia japonesa, china y africana.

Frequency

Huntington's disease affects an estimated 3 to 7 per 100,000 people of European ancestry. The disorder appears to be less common in some other populations, including people of Japanese, Chinese, and African descent.

Fuentes del Ejercicio 6

- [NCBI Gene 3064 \(HTT\)](#) · [OMIM #143100](#) · [OMIM *613004 \(HTT\)](#)
- [Ensembl ENSG00000197386](#)
- [UniProt P42858](#) · [GeneCards HTT](#)
- [KEGG hsa05016 — Huntington disease](#) · [ClinVar Variation ID 409](#)
- [MedlinePlus — Huntington disease](#) · [Biostars — RefSeq vs Ensembl](#)
- [NCBI Insights — HomoloGene redirige a NCBI Datasets/Gene \(2024\)](#)
- [Wikipedia — Huntingtin](#)

Anexo — Cómo ejecutar los scripts

Requisitos: Docker Desktop instalado y corriendo.

```
# Entrar al contenedor
docker compose run tp bash

# Ejercicios de la Parte 2
python src/ex4_blast_parser.py "Mus musculus" # Genera output/ex4_hits.fasta
python src/ex5_emboss.py                      # Genera output/ex5_*.fasta y
ex5_domains.txt
```